

PROIECT DDUM

Detectia Melanomului cu Machine Learning

Mita Alexandra

Dataset	SIIM-ISIC 2020 Melanoma Classification
Sursa	International Skin Imaging Collaboration (ISIC)
Algoritmi	Logistic Regression + Random Forest
Obiectiv	Clasificare binara: Benign (0) vs Malignant/Melanom (1)
Nr. observatii	33.126 leziuni cutanate de la >2.000 pacienti
Nr. variabile	9 features dupa preprocesare (3 originale + 6 OHE)

1. Descrierea Setului de Date

Setul de date utilizat este **SIIM-ISIC 2020 Melanoma Classification Dataset**, furnizat de International Skin Imaging Collaboration (ISIC) si disponibil public pe platforma Kaggle. Datele provin din centre medicale internationale: Memorial Sloan Kettering Cancer Center (New York), Medical University of Vienna si Hospital Clinic de Barcelona.

Setul contine **33.126 de inregistrari** reprezentand leziuni cutanate unice de la **peste 2.000 de pacienti**. Toate diagnosticile de melanom au fost **confirmate histopatologic** (biopsie), iar cele benigne prin acord de experti sau monitorizare longitudinala.

1.1 Tipul datelor, numarul de observatii si variabile

Dupa incarcarea fisierului `train.csv` si inspectia initiala, setul are urmatoarea structura:

Caracteristica	Tip	Descriere	Valori lipsa
image_name	String	ID unic imagine — exclus (nu e feature clinic)	0
patient_id	String	ID pacient — exclus (identificator, nu feature)	0
sex	Categoric	Sexul pacientului: male / female	65 (0.20%)
age_approx	Numeric	Varsta aproximativa la momentul imaginii (ani)	68 (0.21%)
anatom_site_general_challenge	Categoric	Localizarea leziunii: torso, head/neck, lower extremity, upper extremity, palms/soles, oral/genital	527 (1.59%)
target	Binar	VARIABILA TINTA: 0 = Benign, 1 = Malignant (Melanom)	0

1.2 Distributia variabilei tinta (dezechilibru major)

Setul de date este **puternic dezechilibrat**: 32.542 cazuri benigne (98.2%) fata de doar **584 cazuri maligne (1.8%)**. Aceasta are implicatii majore: un model care prezice mereu "benign" ar obtine 98.2% Accuracy fara nicio valoare diagnostica. De aceea metricile principale sunt **Recall** si **ROC-AUC**, nu Accuracy.

Clasa	Nr. cazuri	Procent	Semnificatie
Benign (0)	32.542	98.2%	Leziune cutanata necanceroasa
Malignant (1)	584	1.8%	Melanom confirmat histopatologic
TOTAL	33.126	100%	




Figura 1. Distributia claselor: 98.2% benign vs 1.8% malignant — dezechilibru sever ce impune Recall si ROC-AUC ca metrice principale

1.3 Explorarea datelor (EDA)

Înainte de preprocesare, am analizat distributia variabilelor si relatia lor cu target-ul.

Varsta

Varsta medie a pacientilor maligni este **58.1 ani** fata de **48.7 ani** la cei benigni — o diferenta semnificativa de ~10 ani. Riscul creste vizibil dupa 50 de ani.




Figura 2. Distributia varstei: melanomul afecteaza predominant pacientii de peste 50 de ani (mediana: 60 ani vs 45 ani)

Sex si localizare anatomica

Barbatii prezinta o rata de malignitate de 2.13% fata de 1.38% la femei. Dupa localizare, leziunile de pe **head/neck** au cea mai mare rata (~3.8%), urmate de oral/genital (~3.2%). Palms/soles au cea mai mica rata (~1.4%).




Figura 3. Rata de malignitate per sex si per localizare anatomica: head/neck prezinta cel mai mare risc

2. Metodele si Algoritmii Utilizati

2.1 Preprocesarea datelor

Fluxul complet de preprocesare, urmarind pasii din laboratoarele cursului:

Pasul 1 — Eliminarea coloanelor irelevante si a data leakage

Am eliminat 4 coloane:

- `image_name`, `patient_id` — identificatori unici, nu contin informatie clinica
- `diagnosis` — contine "melanoma" EXCLUSIV pentru cazurile maligne (`target=1`) → data leakage
- `benign_malignant` — echivalent text al `target`-ului → data leakage

```
# Verificare cross-tab diagnosis vs target:
# diagnosis      target=0  target=1
# melanoma              0      584  ← leakage perfect!
# unknown             27124      0
# nevus                5193      0

df_model = df.drop(columns=["image_name", "patient_id",
                           "diagnosis", "benign_malignant"])
```

Pasul 2 — Encoding variabile categorice

Algoritmii ML lucreaza exclusiv cu valori numerice, deci variabilele categorice trebuie convertite:

- **sex** (binar, 2 valori) → **Label Encoding**: male=1, female=0
- **anatom_site_general_challenge** (6 categorii nominale, fara ordine) → **One-Hot Encoding** cu `dummy_na=True` (valorile lipsa devin coloana separata)

```
df_model["sex"] = df_model["sex"].map({"male": 1, "female": 0})

# One-Hot Encoding pentru anatom_site (6 categorii → 7 coloane)
df_model = pd.get_dummies(df_model,
                          columns=["anatom_site_general_challenge"],
                          drop_first=False, # pastram toate categoriile
                          dummy_na=True,   # coloana separata pentru NaN
                          dtype=int)

# Rezultat: 9 features totale
# sex, age_approx, site_head/neck, site_lower extremity,
# site_oral/genital, site_palms/soles, site_torso,
# site_upper extremity, site_nan
```

Pasul 3 — Tratarea valorilor lipsa

Coloana	Nr. lipsa	Strategie	Justificare
age_approx	68 (0.21%)	Mediana	Distributie asimetrica — mediana e robusta la outliers
sex	65 (0.20%)	Modul	Variabila binara — cea mai frecventa valoare (male)
anatom_site	527 (1.59%)	Coloana NaN	<code>dummy_na=True</code> creeaza coloana separata — info pastrata

Pasul 4 — Impartirea datelor (split stratificat 70/15/15)

Deoarece setul este dezechilibrat (98.2%/1.8%), am folosit **stratify=y** pentru a pastra proportia claselor in fiecare subset. Setul de test este folosit o singura data, la evaluarea finala.

Set	Proportie	Nr. exemple	Nr. melanom	Scop
Antrenare (train)	70%	23.188	409	Invatare parametri
Validare (val)	15%	4.969	88	Ajustare hiperparametri
Testare (test)	15%	4.969	87	Evaluare finala
TOTAL	100%	33.126	584	




Figura 4. Verificarea stratificarii: proportia 98.2%/1.8% este pastrata identic in toate cele 3 seturi

Pasul 5 — Scalarea caracteristicilor

StandardScaler (Z-score) a fost aplicat pentru Logistic Regression. Regula critica: `fit()` DOAR pe train, `transform()` pe val si test.

```
scaler = StandardScaler()
X_train_sc = scaler.fit_transform(X_train) # fit + transform pe train
X_val_sc   = scaler.transform(X_val)      # DOAR transform
X_test_sc  = scaler.transform(X_test)     # DOAR transform
# Random Forest NU necesita scalare → folosim X_train, X_val, X_test direct
```

2.2 Algoritmul 1 — Logistic Regression

Justificarea alegerii: Logistic Regression este modelul de referinta (baseline) pentru clasificarea binara. Modeleaza probabilitatea de apartanenta la o clasa prin functia sigmoida aplicata unei combinatii liniare a caracteristicilor: $P(y=1|x) = \sigma(\beta_0 + \beta_1x_1 + \dots + \beta_px_p)$. Este simplu, interpretabil si rapid — ideal ca punct de comparatie.

Hiperparametrul `class_weight="balanced"` ajusteaza automat ponderile claselor invers proportional cu frecventa lor: clasa "malignant" (1.8%) primeste o pondere de ~54x mai mare decat clasa "benign" (98.2%), compensand dezechilibrul.

```
lr = LogisticRegression(
    class_weight="balanced", # compenseaza dezechilibrul 98%/2%
    max_iter=1000,          # iteratii suficiente pentru convergenta
    random_state=42          # reproductibilitate
)
lr.fit(X_train_sc, y_train) # necesita date SCALATE
```




Figura 5. Coeficientii LR: age_approx (0.54) este cel mai puternic factor; torso (-0.11) scade riscul relativ

2.3 Algoritmul 2 — Random Forest

Justificarea alegerii: Random Forest este un model de ansamblu bazat pe **bagging** (Bootstrap Aggregating): antreneaza N arbori de decizie pe subseturi aleatorii ale datelor si combina predictiile prin vot majoritar. Avantaje cheie fata de Logistic Regression:

- **Captureaza relatii neliniare** — nu presupune liniaritate intre features si target
- **Robust la outlieri** — impartirile pe baza de Gini nu sunt afectate de valorile extreme
- **Nu necesita scalare** — arborii de decizie lucreaza cu valori originale
- **Feature importance** — masoara contributia fiecarei caracteristici prin reducerea impuritatii Gini

```
rf = RandomForestClassifier(
    n_estimators=200,          # 200 arbori de decizie
    class_weight="balanced",   # compenseaza dezechilibrul
    random_state=42,          # utilizeaza toate core-urile CPU
    n_jobs=-1
)
rf.fit(X_train, y_train)     # NU necesita scalare
```




Figura 6. Importanta caracteristicilor RF: age_approx domina cu 74.4% din puterea predictiva totala

3. Impartirea Setului de Date (Training / Testing)

Am folosit o impartire in **trei seturi** (train/validare/test), realizata in doi pasi consecutivi cu `train_test_split` din `scikit-learn`, cu `stratify=y` in ambii pasi.

3.1 De ce 3 seturi in loc de 2?

Set	Proportie	Scop	Detalii
Train	70%	Antrenare modele	Modelul vede si invata din aceste date. 23.188 exemple.
Validare	15%	Tuning hiperparametri	Ajustam hiperparametrii fara a "contamina" testul. 4.969 exemple.
Test	15%	Evaluare finala	Modelul NU vede aceste date pana la final. O singura utilizare. 4.969 exemple.

3.2 Importanta stratificarii

Deoarece clasele sunt dezechilibrate (98.2% / 1.8%), fara stratificare am putea obtine un set de test cu 0 sau foarte putine melanome, facand evaluarea imposibila. `stratify=y` garanteaza ~87 melanome in testare si ~88 in validare.

```
# Pasul 1: train (70%) + temp (30%)
X_train, X_temp, y_train, y_temp = train_test_split(
    X, y, test_size=0.30, random_state=42, stratify=y)

# Pasul 2: val (15%) + test (15%) din temp
X_val, X_test, y_val, y_test = train_test_split(
    X_temp, y_temp, test_size=0.50, random_state=42, stratify=y_temp)

# Verificare: proportia se mentine
# Train:      23188 ex → 409 melanom (1.8%)
# Validare:   4969 ex →  88 melanom (1.8%)
# Test:       4969 ex →  87 melanom (1.8%)
```

4. Antrenarea Modelelor si Obtinerea Rezultatelor

4.1 Metricile de evaluare — de ce nu Accuracy?

Pentru date dezechilibrate, **Accuracy este inselatoare**. Un model care prezice mereu "benign" obtine 98.2% Accuracy — dar detecteaza 0 melanome! Metricile relevante sunt:

Metrica	Formula	Interpretare medicala
Accuracy	$(TP+TN) / Total$	Proportia predictiilor corecte — inutila singura
Precision	$TP / (TP+FP)$	Din cei prezisi ca melanom, cati chiar sunt?
Recall ★	$TP / (TP+FN)$	Din toti melanomii reali, cati au fost detectati? — CRITICA
F1-Score	$2 \cdot P \cdot R / (P+R)$	Media harmonica Precision-Recall — echilibru
ROC-AUC ★	Aria sub curba ROC	Performanta globala, independenta de prag — CRITICA

4.2 Rezultatele Logistic Regression (default)

Set	Accuracy	Precision	Recall	F1	ROC-AUC
Train	0.6508	0.0318	0.6381	0.0606	0.6894
Validare	0.6508	0.0292	0.5795	0.0555	0.6560
Test	0.6490	0.0338	0.6897	0.0644	0.7025

4.3 Rezultatele Random Forest (default)

Set	Accuracy	Precision	Recall	F1	ROC-AUC
Train	0.7324	0.0409	0.6308	0.0768	0.7493
Validare	0.7205	0.0269	0.4205	0.0506	0.6198
Test	0.7134	0.0335	0.5517	0.0632	0.6670




Figura 7. Matrici de confuzie: LR detecteaza 60 melanome cu 27 ratate (FN); RF detecteaza 48 cu 39 ratate




Figura 8. Curbe ROC: LR (AUC=0.703) depaseste RF default (AUC=0.667) — surprinzator pe acest dataset

5. Evaluarea Performantei Modelelor

5.1 Raport de clasificare complet — Logistic Regression

	precision	recall	f1-score	support
Benign	0.99	0.65	0.78	4882
Malignant	0.03	0.69	0.06	87
accuracy			0.65	4969
macro avg	0.51	0.67	0.42	4969
weighted avg	0.97	0.65	0.77	4969

5.2 Raport de clasificare complet — Random Forest

	precision	recall	f1-score	support
Benign	0.99	0.72	0.83	4882
Malignant	0.03	0.55	0.06	87
accuracy			0.71	4969
macro avg	0.51	0.63	0.45	4969
weighted avg	0.97	0.71	0.82	4969

5.3 Analiza matricei de confuzie

Model	TN	FP	FN Δ	TP	Recall	Specificity
Logistic Regression (default)	3165	1717	27	60	0.690	0.648
RF (optimizat)	3497	1385	39	48	0.621	0.716

FN (rosu) = melanom diagnosticat gresit ca benign — cea mai periculoasa eroare. LR produce mai putine FN (27 vs 39), deci este preferata in screening initial.

6. Optimizarea Hiperparametrilor

Am folosit **GridSearchCV** cu validare incrucisata **StratifiedKFold (5 folduri)** pentru ambii algoritmi. Metrica de optimizare: **ROC-AUC** — mai robusta decat Accuracy pe date dezechilibrate.

```
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

grid = GridSearchCV(
    estimator,
    param_grid,
    cv=cv,
    scoring="roc_auc",    # optimizam ROC-AUC, nu Accuracy!
    n_jobs=-1,           # paralel pe toate core-urile
    verbose=1
)
```

6.1 Optimizare Random Forest (36 combinatii, 180 fits)

Hiperparametru	Valori testate	Valoare optima	Justificare
n_estimators	[100, 200, 300]	200	Echilibru viteza/stabilitate
max_depth	[5, 10, 20, None]	5	Limiteaza overfitting
min_samples_leaf	[1, 5, 10]	10	Regularizare

Cel mai bun ROC-AUC (CV 5-fold): 0.6757

6.2 Optimizare Logistic Regression (12 combinatii, 60 fits)

Hiperparametru	Valori testate	Valoare optima	Justificare
C	[0.001, 0.01, 0.1, 1, 10, 100]	0.01	Regularizare puternica
penalty	[l1, l2]	l1	Sparse → mai interpretabil
solver	liblinear	liblinear	Suporta L1 + L2

Cel mai bun ROC-AUC (CV 5-fold): 0.6814

6.3 Rezultatele modelelor optimizate

Model	Accuracy	Precision	Recall	F1	ROC-AUC
LR default	0.6490	0.0338	0.6897	0.0644	0.7025
LR optimizat (C=0.01, L1)	0.6363	0.0331	0.7011	0.0632	0.7051
RF default	0.7134	0.0335	0.5517	0.0632	0.6670
RF optimizat (depth=5, leaf=10)	0.7327	0.0400	0.6207	0.0752	0.7053

7. Comparatia Rezultatelor si Interpretarea

7.1 De ce Accuracy nu este metrica potrivita?

RF obtine Accuracy = 73.3%, aparent mai buna decat LR (64.9%). Insa aceasta diferenta este **inselatoare**: RF prezice "benign" mai agresiv, sacrificand detectia melanomului. Un model care prezice mereu "benign" ar obtine **98.2% Accuracy** — dar ar rata TOATE melanomele.

7.2 Comparatie din perspectiva medicala

In contextul detectiei melanomului, contextul medical impune prioritizarea **Recall**: un FN (melanom nedagnosticat) poate fi fatal. Un FP (benign diagnosticat ca melanom) duce la o biopsie — incomod, dar nu periculos.

Logistic Regression optimizata este preferata pentru **screening initial**: Recall = 0.701 — detecteaza 61 din 87 melanome din setul de test. **Random Forest optimizat** este preferat daca dorim un **echilibru global mai bun**: ROC-AUC = 0.705 si F1 = 0.075 (mai bun decat LR).




Figura 9. Comparatie finala: LR opt are cel mai bun Recall; RF opt are cel mai bun F1 si ROC-AUC

7.3 Observatii cheie din EDA si importanta caracteristicilor

Caracteristica	Imp. Gini (RF)	Interpretare
age_approx	0.7444	Cel mai puternic predictor. Varsta medie melanom: 58.1 ani vs 48.7 ani benign. Riscul creste dupa 50 ani.
sex	0.0856	Barbatii: rata 2.13% vs femei 1.38%. Coeficient LR: +0.21 (creste riscul).
head/neck	0.0391	Cea mai mare rata de malignitate (~3.8%). Coeficient LR pozitiv (+0.13).
torso	0.0336	Coeficient LR negativ (-0.11) — relativ protectiv fata de head/neck.
upper extremity	0.0284	Rata de malignitate ~2.2%. Coeficient LR pozitiv (+0.12).

7.4 Limitele modelului si directii viitoare

Modelele actuale au **performante moderate** (ROC-AUC ~ 0.70) din cauza numarului redus de caracteristici clinice: varsta, sex si localizare anatomica. Modele CNN pe imaginile dermoscopice ating ROC-AUC de 0.87-0.93 pe acelasi dataset.

- **Adaugarea de features din imagini:** media RGB, textura (LBP), asimetria leziunii
- **SMOTE** (Synthetic Minority Oversampling) pentru generarea de exemple sintetice din clasa minoritara
- **Gradient Boosting** (XGBoost, LightGBM) — mai bun pe date tabelare dezechilibrate
- **Ajustarea pragului de decizie:** in loc de 0.5 implicit, un prag de 0.2-0.3 ar maximiza Recall

8. Concluzii

Acest proiect a demonstrat aplicarea unui flux complet de Machine Learning pe un dataset medical real de detectie a melanomului. Principalele concluzii:

1. **Varsta** este predictorul dominant (importanta Gini = 0.744). Varsta medie a pacientilor maligni este 58.1 ani vs 48.7 ani la cei benigni.
2. **Dezechilibrul sever** (98.2%/1.8%) impune `class_weight="balanced"` si evaluarea cu Recall + ROC-AUC in locul Accuracy-ului simplu.
3. **Logistic Regression optimizata** (C=0.01, L1) obtine cel mai bun **Recall = 0.701** — detecteaza 61 din 87 melanome din testare.
4. **Random Forest optimizat** (max_depth=5, min_samples_leaf=10) obtine cel mai bun echilibru: **ROC-AUC = 0.705** si **F1 = 0.075**.
5. Surprinzator, LR a egalat RF la ROC-AUC, sugerand ca relatiile disponibile sunt quasi-liniare cu putinele features disponibile.
6. **GridSearchCV** cu StratifiedKFold (5 folduri) a imbunatatit Recall RF de la 0.552 (default) la 0.621 (optimizat) si ROC-AUC de la 0.667 la 0.705.
7. Performanta moderata (ROC-AUC ~ 0.70) indica ca datele clinice tabelare singure sunt insuficiente; imaginile dermoscopice sunt esentiale pentru diagnostic precis.